

UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE ENGENHARIA QUÍMICA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA QUÍMICA



Sistemas Inteligentes baseados em Redes Neurais Artificiais aplicados ao Processamento de Imagens no cálculo da Distribuição do Tamanho das Partículas (PSD)

ALUNA: Maria Gabriela Marques

ORIENTADOR: Ubirajara Coutinho Filho

UBERLÂNDIA, MG

2021


SUMÁRIO:

- Introdução
- Objetivos
- Revisão Bibliográfica
- Metodologia
- Resultados e discussões
- Conclusões

SUMÁRIO:

- **Introdução**
- Objetivos
- Revisão Bibliográfica
- Metodologia
- Resultados e discussões
- Conclusões

- A todo momento estamos fazendo **reconhecimento de padrões**:
 - Ao ler este texto,
 - Reconhecer o rosto de uma pessoa,
 - Distinguir um cachorro de um gato,
 - Ler as diversas caligrafias e
 - Até mesmo interpretar um exame de eletrocardiografia.
- A **Inteligência Artificial** é um dos **ramos da ciência da computação** que **simula a inteligência humana** através do desenvolvimento de softwares. Explora os mecanismos da mente possibilitando o pensamento e a ação inteligente.



Um desses mecanismos utiliza a maneira como o cérebro realiza uma tarefa.

- **Redes Neurais Artificiais (RNA)** possuem a capacidade de **se adaptar** e de **aprender** a realizar uma certa tarefa à partir de um conjunto de dados.

- Há uma grande demanda por **métodos automatizados** de **análise** no controle do processo produtivo dentro da indústria:
 - Melhorar a velocidade de resposta
 - Uniformizar a análise
 - Diminuir custo operacional
- A análise da **Distribuição do Tamanho das Partículas (PSD)** desempenha um papel importante dentro da indústria e o seu resultado impacta diretamente nas **propriedades** e **qualidade** dos materiais.
- O PSD é um dos **parâmetros de Controle de Qualidade** na produção de Açúcar.

SUMÁRIO:

- Introdução
- **Objetivos**
- Revisão Bibliográfica
- Metodologia
- Resultados e discussões
- Conclusões


Propor um sistema de controle de qualidade de materiais particulados por meio do fornecimento da análise da distribuição granulométrica automática *in-line* à partir da análise de imagens utilizando como referência o açúcar VHP e um sistema de microscopia compacto com conectividade IoT de baixo custo

- 1. Desenvolver um Sistema de aquisição de imagens com conectividade IoT, alta resolução, baixo custo, cujas imagens possam ser processadas em tempo real.**
- 2. Treinar redes neurais capazes de identificar os cristais de forma automática sem a necessidade de entregar a amostra no laboratório.**
- 3. Associar as RNA a um software capaz de gerar o PSD à partir de imagens em tempo real.**

1



2



SUMÁRIO:

- Introdução
- Objetivos
- **Revisão Bibliográfica**
- Metodologia
- Resultados e discussões
- Conclusões

1. Materiais particulados:

- Os materiais na **forma de pó e os particulados** ocupam a **2ª posição em escala de uso** dentro da indústria química, atrás somente da água.
- Um dos métodos mais popular para a estimativa do tamanho das partículas é o **Peneiramento Mecânico** ou **Granulometria**.
- No entanto, apresenta certas limitações:

- Custo operacional e instalações laboratoriais,
- Tempo de análise,
- Não uniformização da análise,
- Perda de material (retido na peneira ou quebras com a vibração),
- Alguns materiais podem reagir quimicamente com a peneira.




- Açúcar:

- O açúcar é produzido em **mais de 100 países**, sendo o **Brasil** o **maior produtor** e **exportador mundial**.
- No Brasil, representa a **3ª cultura temporária**, somente atrás da soja e o milho.
- **Açúcar bruto** cuja polarização é maior que 99,2°S é chamado de VHP (*very high polarization*) **polarização muito alta**.




- Para atender as demandas, o **controle de qualidade do açúcar** deve ser rigoroso de forma a atender as especificações por norma.



2. Processamento de imagens:

- Imagem digital:

- Cada posição na imagem contém um valor proporcional a intensidade luminosa nessa posição, correspondendo ao pixel.
- Uma imagem pode ser definida como uma função $f(x,y)$.



- Essa luminosidade é convertida em cor e varia entre 0 e 255 (0 cor preta e 255 cor branca).

3. Uso de redes neurais no processamento de imagens:

- Dentre as técnicas de Reconhecimento de Padrões, a abordagem conexionista utiliza RNAs.

Capazes de se adaptarem a qualquer tipo de distribuição de dados


Inspirada no funcionamento das redes de neurônios do cérebro.

Faz processamento de informações em paralelo.

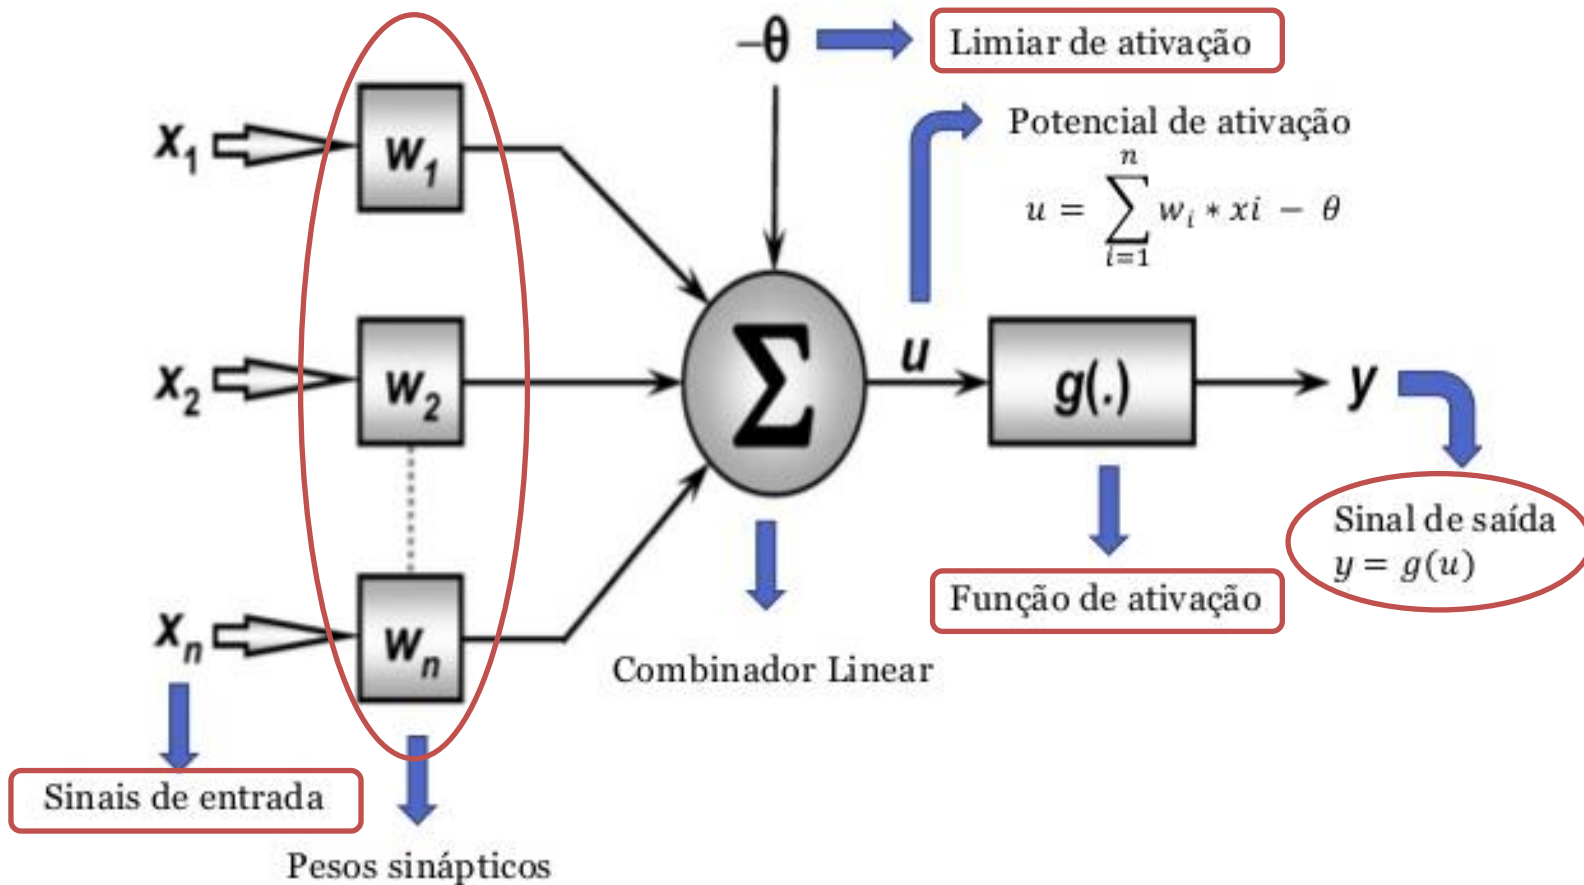
Capacidade de generalizar

O fato de serem uma “caixa preta”

- Neurônio Biológico:




- Neurônio Matemático:




- Neurônio Matemático (função de ativação):

sigmoid




$$\varphi(v) = \frac{1}{1 + e^{-v^2}}$$

tanh




$$\varphi(v) = \tanh(v)$$

ReLU



$$\varphi(v) = \begin{cases} 0 & \text{for } v < 0 \\ v & \text{for } v \geq 0 \end{cases}$$


- Rede Neural (DNN *Feedforward*):



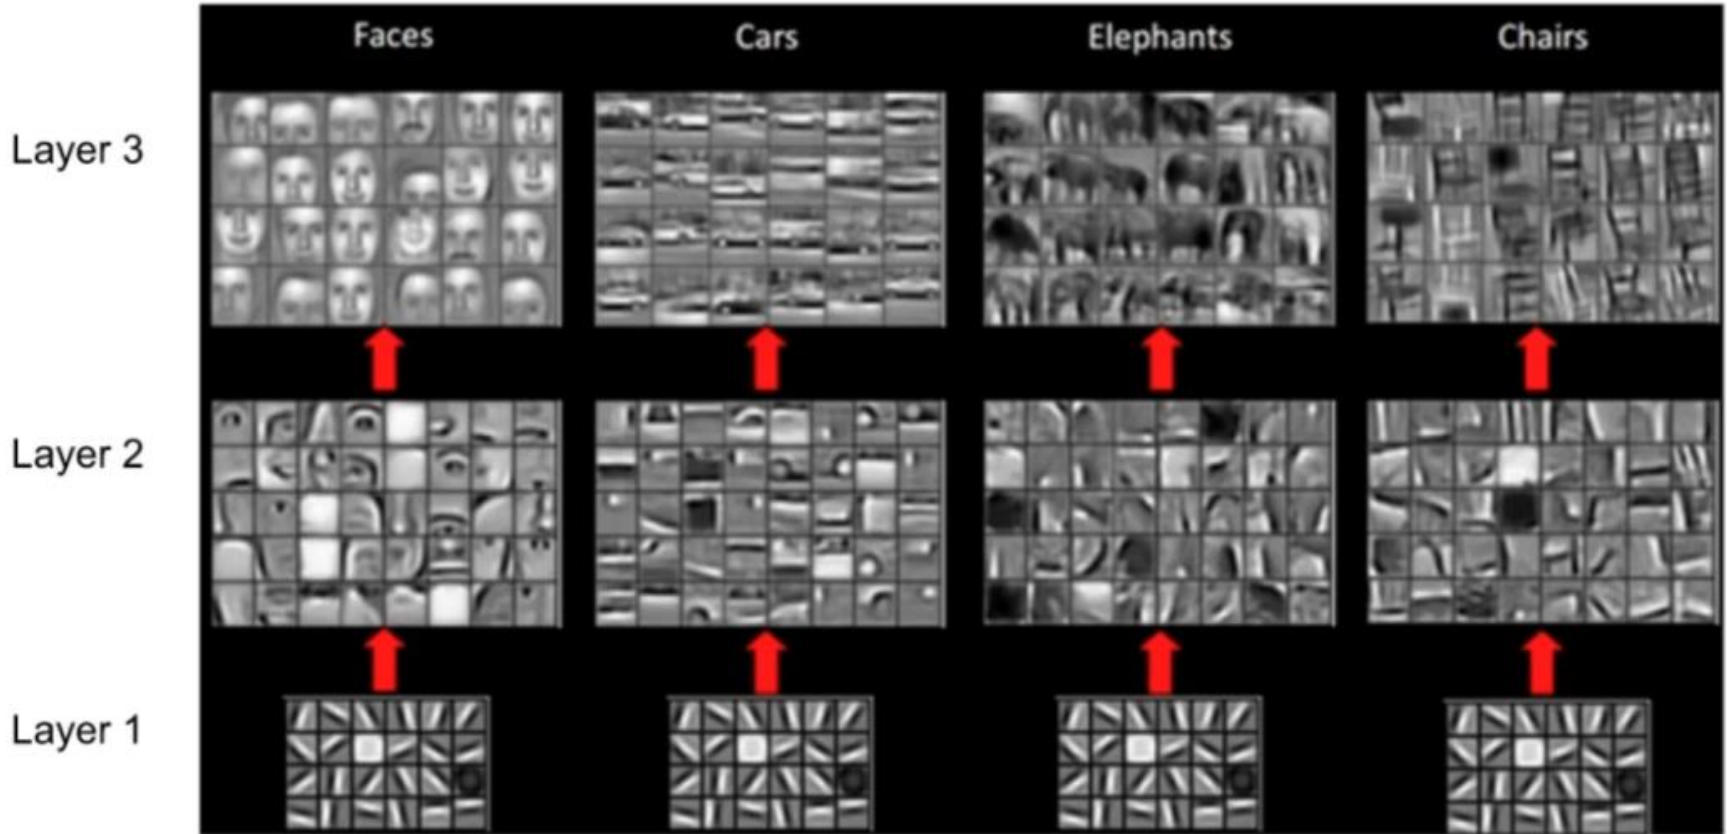
- *Deep learning*
- *Feedforward*
- *Backpropagation*

- Rede Neural de Convolução (CNN):


- CNN tem inspiração biológica, assim como DNN *Feedforward*.
- *Hubel e Weizel* estudaram o **cortex visual** (prêmio nobel de Medicina 1981). Os neurônios no cortex visual **tem um pequeno campo receptivo local**.



- Rede Neural de Convolução (CNN):



- Rede Neural de Convolução (CNN):



$$CE = - \sum_{i=1}^C t_i \log(s_i) = -t_1 \cdot \log(s_1) - (1 - t_1) \cdot \log(1 - s_1)$$

SUMÁRIO:

- Introdução
- Objetivos
- Revisão Bibliográfica
- **Metodologia**
- Resultados e discussões
- Conclusões

1. Linguagem de Programação:


- Sintaxe intuitiva
- Programação de código aberto
- Diversas fontes de informações (grande comunidade ativa)




2. Materiais:

- 9 amostras de Açúcar VHP vieram de 2 empresas locais do Triângulo Mineiro.




3. Representação esquemática da amostragem *in-line* para o cálculo do PSD:



4. Aquisição da imagem:



MC: Microscópio Conexão
CS: Sistema do Computador
LS: Sistema de Iluminação
MS: Sistema do Microscópio
CC: Conexão do Computador
CH: Suporte para os cristais

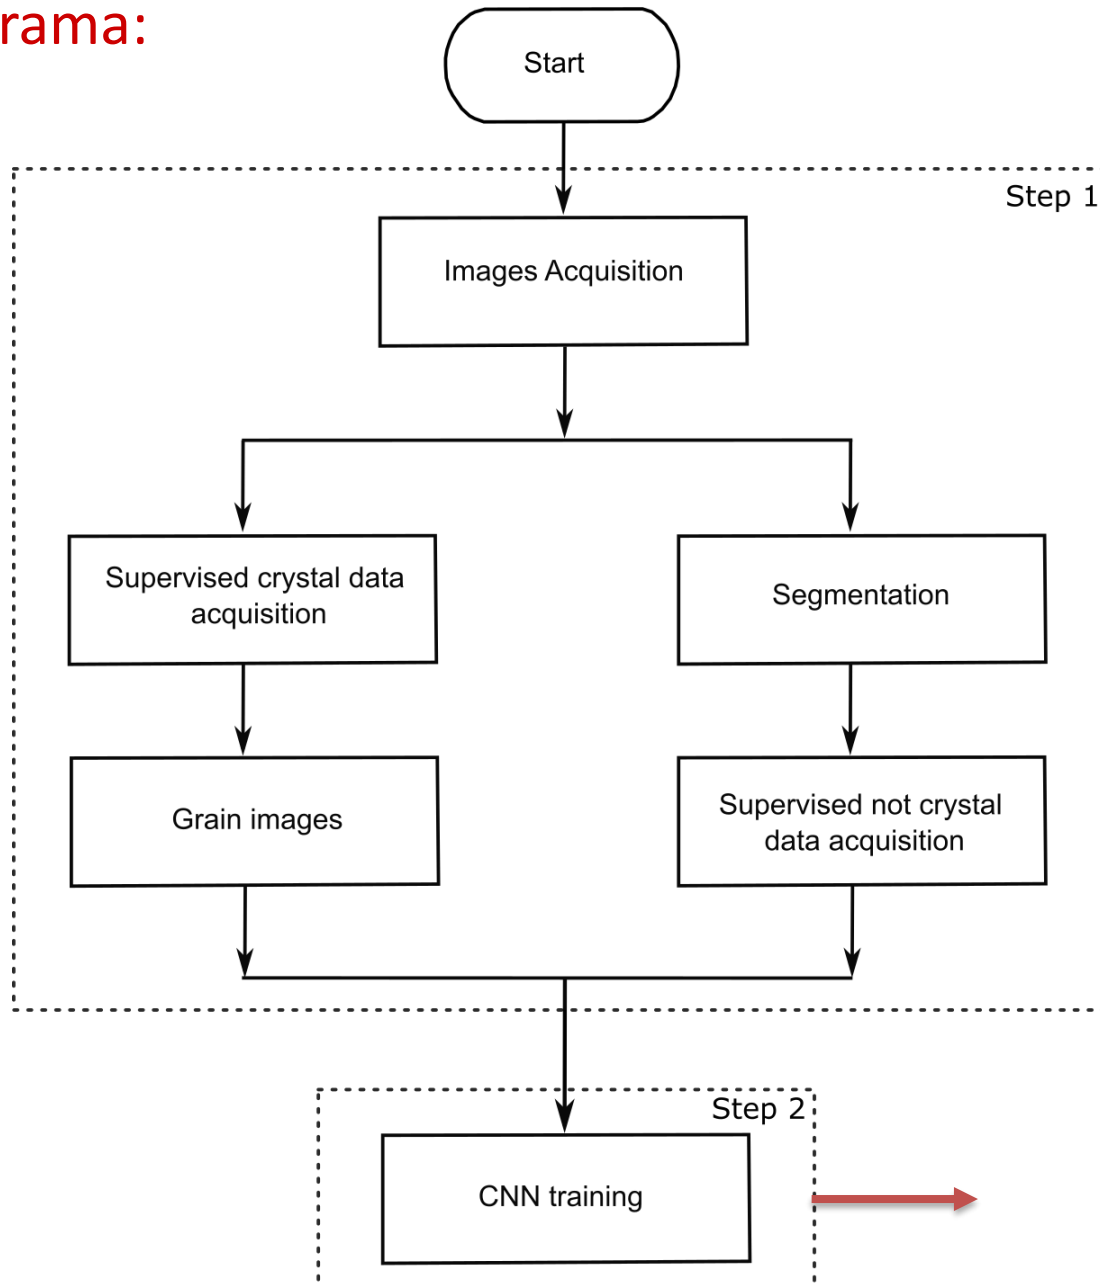


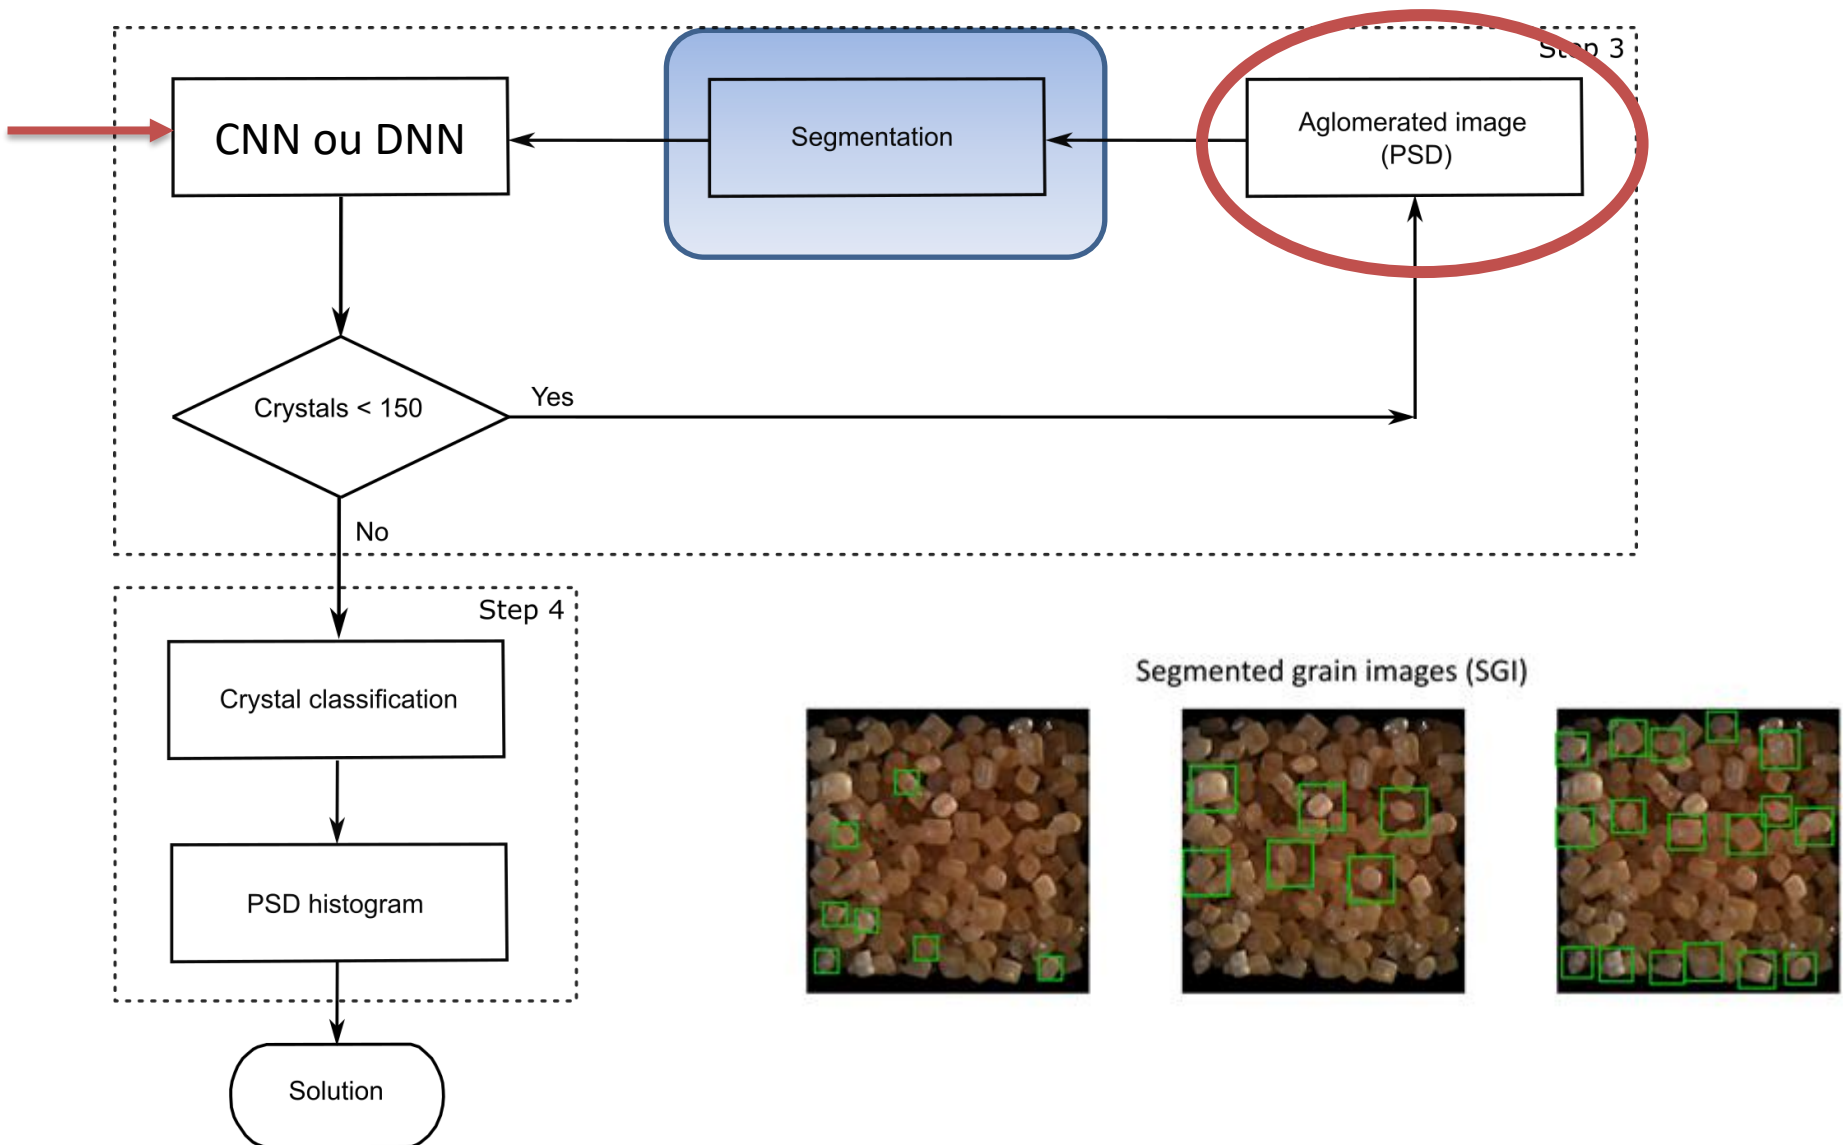
CH
X= 14,13mm
Y= 12,76mm
Z= 4,78mm

5. Redes Neurais Avaliadas:

RNAs	Neurônios (camadas da CNN)	Neurônios (camadas ocultas)
CNN-32-64-128-D-200-10	32, 64, 128	200, 10
CNN-32-64-128-D-100-100	32, 64, 128	100, 100
CNN-32-64-128-D-200-200	32, 64, 128	200, 200
CNN3-32-64-128-D-50-50	32, 64, 128	50, 50
CNN-32-64-128-D-20-20	32, 64, 128	20, 20
CNN-64-128-256-D-200-10	64, 128, 256	200, 10
CNN-64-128-256-D-100-100	64, 128, 256	100, 100
CNN-64-128-256-D-200-200	64, 128, 256	200, 200
CNN-64-128-256-D-50-50	64, 128, 256	50, 50
CNN-64-128-256-D-20-20	64, 128, 256	20, 20
CNN-32-64-128-256-512-D-200-10	32, 64, 128, 256, 512	200, 10
CNN-32-64-128-256-512-D-100-100	32, 64, 128, 256, 512	100, 100
CNN-32-64-128-256-512--D-200-200	32, 64, 128, 256, 512	200, 200
CNN-32-64-128-256-512-D-50-50	32, 64, 128, 256, 512	50, 50
CNN-32-64-128-256-512--D-20-20	32, 64, 128, 256, 512	20, 20
DNN-D-200-10	0 (sem convolução)	200, 10
DNN-D-100-100	0 (sem convolução)	100, 100
DNN-D-200-200	0 (sem convolução)	200, 200
DNN-D-50-50	0 (sem convolução)	50, 50
DNN-D-20-20	0 (sem convolução)	20, 20

6. Fluxograma:





SUMÁRIO:

- Introdução
- Objetivos
- Revisão Bibliográfica
- Metodologia
- **Resultados e discussões**
- Conclusões

1. Base de Dados:

- 3530 imagens de açúcar VHP.
- O sistema de aquisição de imagens produz **imagens de alta qualidade** e detecta a variação de cor do açúcar VHP industrial.



A



B




C



D



E



F

1. Base de Dados:


- Sistema de aquisição de imagens de **baixo custo**.

PSD	Jogo de peneiras	Agitador de peneiras	Custo unitário da mão de obra	2 Luminárias LED	Microscópio USB portátil	Raspberry pi	Total
Manual	R\$ 1.848,00	R\$ 9.916,84	R\$ 4.267,45				R\$ 28.834,64
Proposto				R\$ 110,00	R\$ 76,91	R\$ 419,00	R\$ 605,91

- A **metodologia proposta** pode ser utilizada em processos planta (**PIMS**) e em escala laboratorial (**LIMS**), ao passo que a abordagem com **peneiras** contempla somente **LIMS**.

2. Segmentação Automática:

- 25 imagens obtidas de forma **randômica** à partir das imagens de **cristais aglomerados** utilizando o código.
- Verifica-se a **geração mais frequente de imagens não-grãos** durante a segmentação automática.
- 750 imagens segmentadas a partir das imagens de cristais aglomerados foram encontrados **18 grãos** e **732 não-grãos**.



3. Desempenho das RNAs avaliadas:

(5x cada configuração)

Ensaio	RNAs	N1	N2	(A) treino	(A) teste
1	CNN-32-64-128-D-200-10	200	10	1	0,91
2	CNN-32-64-128-D-100-100	100	100	1	0,78
3	CNN-32-64-128-D-200-200	200	200	1	0,882
4	CNN3-32-64-128-D-50-50	50	50	0,994	0,865
5	CNN-32-64-128-D-20-20	20	20	0,997	0,729
6	CNN-64-128-256-D-200-10	200	10	1	0,803
7	CNN-64-128-256-D-100-100	100	100	1	0,724
8	CNN-64-128-256-D-200-200	200	200	1	0,698
9	CNN-64-128-256-D-50-50	50	50	1	0,71
10	CNN-64-128-256-D-20-20	20	20	1	0,947
11	CNN-32-64-128-256-512-D-200-10	200	10	0,603	0,58
12	CNN-32-64-128-256-512-D-100-100	100	100	0,999	0,736
13	CNN-32-64-128-256-512--D-200-200	200	200	0,999	0,691
14	CNN-32-64-128-256-512-D-50-50	50	50	0,998	0,595
15	CNN-32-64-128-256-512--D-20-20	20	20	0,998	0,512
16	DNN-D-200-10	200	10	0,972	0,969
17	DNN-D-100-100	100	100	0,99	0,959
18	DNN-D-200-200	200	200	0,997	0,952
19	DNN-D-50-50	50	50	0,974	0,961
20	DNN-D-20-20	20	20	0,948	0,963

4. Desempenho das RNAs avaliadas capacidade de obtenção do PSD associado às RNAs selecionadas:

	AM-3		AM-7		AM-8		R ²
	R ²	SD	R ²	SD	R ²	SD	(Média)
CNN-32-64-128-D-200-10	0,959	0,016	0,850	0,037	0,831	0,056	0,880
CNN-64-128-256-D-20-20	0,957	0,059	0,892	0,058	0,920	0,015	0,923
DNN-D-200-10	0,956	0,050	0,838	0,078	0,910	0,054	0,901



Exemplo:

(20x cada configuração)

N1	N2	R ²	acc test	Details	0.8	1.0	1.2	1.4	1.6	1.8
20	20	0,95	0,97	3 layers of Convolution: 64/128/256	17,65	32,35	11,76	32,35	5,88	0,00

5. Desempenho final do sistema proposto:

Amostra 3	VP	VN	FP	FN	A (%)	P (%)	R (%)	S (%)	F1 (%)
Treino	173	170	0	0	100	100	100	100	100
Validação	71	71	4	1	96,6	94,7	98,6	94,7	96,6

Amostra 7	VP	VN	FP	FN	A (%)	P (%)	R (%)	S (%)	F1 (%)
Treino	175	168	0	0	100	100	100	100	100
Validação	70	73	2	2	97,3	97,2	97,2	97,3	97,2

Amostra 8	VP	VN	FP	FN	A (%)	P (%)	R (%)	S (%)	F1 (%)
Treino	175	168	0	0	100	100	100	100	100
Validação	71	72	3	1	97,3	96	98,6	96	97,3

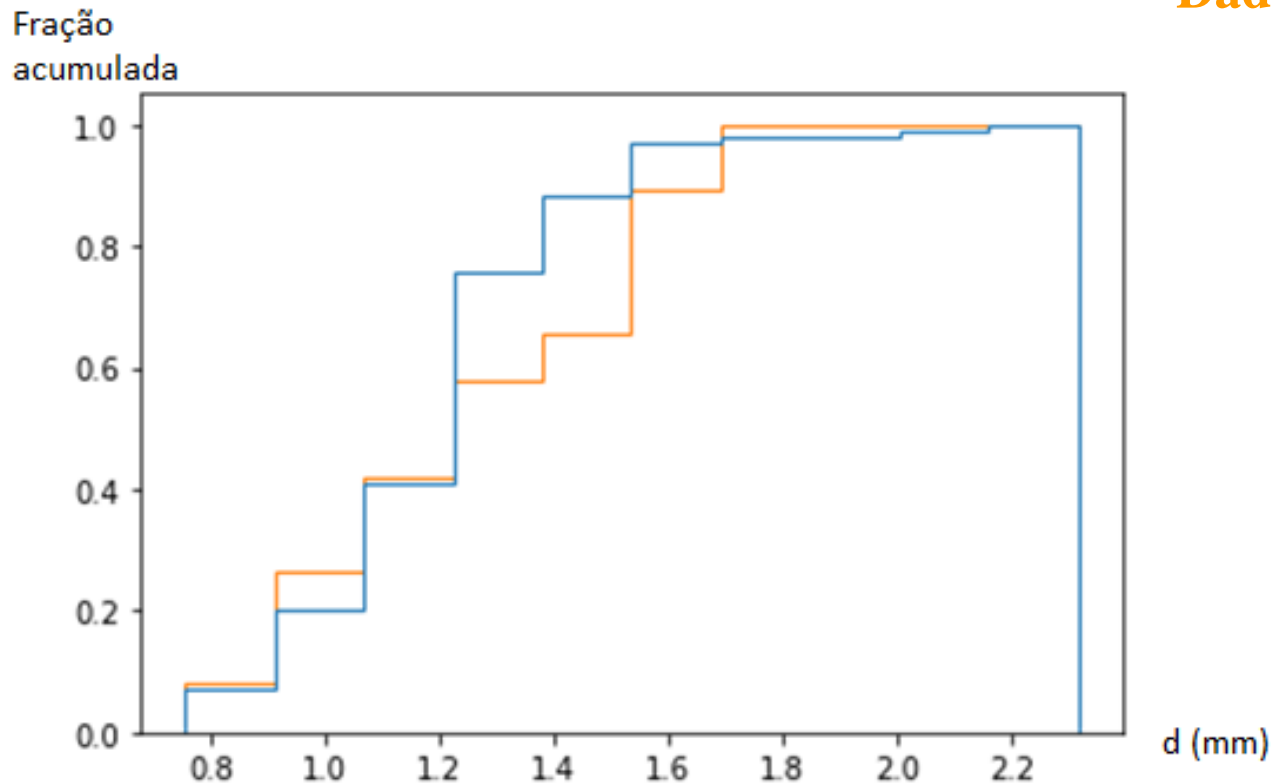
- Frei e Kruis analisaram o tamanho das partículas em microscopia eletrônica de transmissão e encontraram 95,9% de acurácia.
- Octay e Gurses utilizaram microscopia de alta resolução para a detecção e segmentação de nanopartículas e encontraram, respectivamente, 98,2 e 96,6% de acurácia.

5. Desempenho final do sistema proposto:

- Amostra 3:

Dados ImageJ

Dados CNN




5. Desempenho final do sistema proposto:

- Amostra 7:

Dados ImageJ

Dados CNN




5. Desempenho final do sistema proposto:

- Amostra 8:


Dados ImageJ

Dados CNN



6. Histograma PSD:

Amostra 3




($R^2=0,89$)

ImgJ: média= 1,086 desvio= 0,28 pontos= 269


CNN: média= 1,078 desvio= 0,206 pontos= 98

6. Histograma PSD:

Amostra 7



Amostra 8



Amostra 7 ($R^2=0,87$)

Amostra 8 ($R^2=0,86$)

SUMÁRIO:

- Introdução
- Objetivos
- Revisão Bibliográfica
- Metodologia
- Resultados e discussões
- **Conclusões**
- Próximos passos

- O controle de qualidade de cristais de açúcar pode ser realizado pelo sistema proposto nesta tese, cujas imagens são obtidas em tempo real utilizando um dispositivo de baixo custo.
- Referente a etapa de obtenção das imagens, o sistema proposto é adequado para gerar imagens de qualidade.
- Em relação ao uso de aprendizagem de máquina no processamento das imagens, foi constatado que redes neurais artificiais do tipo DNN e do tipo CNN se mostraram capazes de identificar os cristais com acurácia superior a 90%.
- Embora a análise de PSD seja um problema complexo, o uso de segmentação associado as redes neurais, mostrou-se promissor adequado.

Muito Obrigada!

